Revisão bibliográfica

para ciência de dados



O que é?

- Pesquisa por trabalhos similares àquele que queremos desenvolver
- Essencial para qualquer projeto de pesquisa
- Utilizada para conhecer profundamente a área de interesse



Por quê?

- Encontrar gaps na literatura
- Encontrar "competidores"
- Descobrir o estado-da-arte da área
- Reunir estratégias diferentes para atacar um mesmo problema



Por quê?

- Encontrar gaps na literatura
- Encontrar "competidores"
- Descobrir o estado-da-arte da área
- Reunir estratégias diferentes para atacar um mesmo problema



- Relatos de "lições aprendidas" (o que funciona VS o que não funciona)
- Direcionamento maior para o desenvolvimento dos projetos

Como?

- Dois tipos de revisão bibliográfica:
 - Revisão exploratória
 - Revisão sistemática



Revisão Exploratória



Passo 1: Artigo zero

- Artigo inicial que será a semente de busca para os outros estudos
- Loteria: Surveys ou Teses
- Preferível ter artigos em periódicos recentes
- Se não tivermos um artigo zero, podemos fazer uma, busca em repositórios



Artigo zero Palavras-chave

Prefira palavras-chave simples a listas exaustivas.

Stance (detection | classification)

- Stance detection in Social Media
- **~**

2. Unsupervised Stance Classification



3. Rumor Stance detection on Twitter



Artigo zero Palavras-chave

Podemos acabar excluindo paráfrases interessantes.

Stance (detection | classification)

- Stance detection in Social Media
- **₹**

2. Unsupervised Stance Classification



3. Rumor Stance detection on Twitter



 Stance analysis on Tweets

Artigo zero Palavras-chave

Quanto menos palavras, mais abrangente é nossa busca.

Stance

- Stance detection in Social Media
- V

Unsupervised Stance Classification

- \bigcirc
- 3. Rumor Stance detection on Twitter
- **~**

4. Stance analysis on Tweets



Passo 2: Expansão

Para cada artigo, podemos **olhar suas referências** para expandir a lista de artigos de interesse.

- Alastair J. Gill, Scott Nowson, and Jon O ality, topic and motivation in blogs. In IC
- Martin Gütlein. Large scale attribute set thesis, Albert-Ludwigs-Universitat, Freibu
- Mark Andrew Hall and Lloyd Smith. Prac In Proc 21st Australian Computer Scien 1998. Springer.
- S. Herring, L. Scheidt, S. Bonus, and E. V. Technology & People, 18(2):142–171, 200
- Adam D. I. Kramer, Susan R. Fussell, and lyzing conversation in online support ground on Human Factors and Computing System
- Francois Mairesse, Marilyn A. Walker, M guistic cues for the automatic recognition Artificial Intelligence Research, 30:457–50
- Matthias R. Mehl, Samuel D. Gosling, an habitat: manifestations and implicit folk personality and social psychology, 90(5):3
- Scott Nowson. The Language of Weblogs. thesis, University of Edinburgh, 2006.
- Scott Nowson and Jon Oberlander. Identiality classification of personal weblogs. I on Weblogs and Social, 2007.
- Scott Nowson, Jon Oberlander, and Alast ences. In *Proceedings of the 27th Annual Communication* 1666–1671, 2005.
- Jon Oberlander and Alastair J. Gill. Langu of individual differences in e-mail comm 2006.

Passo 2: Expansão

Podemos expandir a lista de artigos por:

- Trabalhos relacionados
- Autores recorrentes

- Alastair J. Gill, Scott Nowson, and Jon Oberlander. What are they blogging about? personality, topic and motivation in blogs. In ICWSM 2009, 2009.
- Martin Gütlein. Large scale attribute selection using wrappers. Master's thesis, Masters thesis, Albert-Ludwigs-Universitat, Freiburg, 2006, 2006.
- Mark Andrew Hall and Lloyd Smith. Practical feature subset selection for machine learning. In Proc 21st Australian Computer Science Conference, pages 181–191, Perth, Australia, 1998. Springer.
- S. Herring, L. Scheidt, S. Bonus, and E. Wright. Weblogs as a bridging genre. Information, Technology & People, 18(2):142–171, 2005.
- Adam D. I. Kramer, Susan R. Fussell, and Leslie D. Setlock. Text analysis as a tool for analyzing conversation in online support groups. In Extended Abstracts of the 2004 conference on Human Factors and Computing Systems, pages 1485–1488, 2004.
- Francois Mairesse, Marilyn A. Walker, Matthias R. Mehl, and Roger K. Moore. Using linguistic cues for the automatic recognition of personality in conversation and text. Journal of Artificial Intelligence Research, 30:457–500, 2007.
- Matthias R. Mehl, Samuel D. Gosling, and James W. Pennebaker. Personality in its natural habitat: manifestations and implicit folk theories of personality in daily life. *Journal of personality and social psychology*, 90(5):862–877, May 2006.
- Scott Nowson. The Language of Weblogs: A study of genre and individual differences. PhD thesis, University of Edinburgh, 2006.
- Scott Nowson and Jon Oberlander. Identifying more bloggers: Towards large scale personality classification of personal weblogs. In In Proceedings of the International Conference on Weblogs and Social, 2007.
- Scott Nowson, Jon Oberlander, and Alastair J. Gill. Weblogs, genres and individual differences. In Proceedings of the 27th Annual Conference of the Cognitive Science Society, pages 1666–1671, 2005.
- Jon Oberlander and Alastair J. Gill. Language with character: A stratified corpus comparison of individual differences in e-mail communication. *Discourse Processes*, 42(3):239–270, 2006.

Passo 2: Expansão

Podemos expandir a lista de artigos por:

- Trabalhos relacionados
- Autores recorrentes

- Alastair J. Gill, Scott Nowson, and Jon Oberlander. What are they blogging about? personality, topic and motivation in blogs. In ICWSM 2009, 2009.
- Martin Gütlein. Large scale attribute selection using wrappers. Master's thesis, Masters thesis, Albert-Ludwigs-Universitat, Freiburg, 2006, 2006.
- Mark Andrew Hall and Lloyd Smith. Practical feature subset selection for machine learning. In Proc 21st Australian Computer Science Conference, pages 181–191, Perth, Australia, 1998. Springer.
- S. Herring, L. Scheidt, S. Bonus, and E. Wright. Weblogs as a bridging genre. Information, Technology & People, 18(2):142–171, 2005.
- Adam D. I. Kramer, Susan R. Fussell, and Leslie D. Setlock. Text analysis as a tool for analyzing conversation in online support groups. In Extended Abstracts of the 2004 conference on Human Factors and Computing Systems, pages 1485–1488, 2004.
- Francois Mairesse, Marilyn A. Walker, Matthias R. Mehl, and Roger K. Moore. Using linguistic cues for the automatic recognition of personality in conversation and text. *Journal of Artificial Intelligence Research*, 30:457–500, 2007.
- Matthias R. Mehl, Samuel D. Gosling, and James W. Pennebaker. Personality in its natural habitat: manifestations and implicit folk theories of personality in daily life. *Journal of personality and social psychology*, 90(5):862–877, May 2006.
- Scott Nowson. The Language of Weblogs: A study of genre and individual differences. PhD thesis, University of Edinburgh, 2006.
- Scott Nowson and Jon Oberlander. Identifying more bloggers: Towards large scale personality classification of personal weblogs. In In Proceedings of the International Conference on Weblogs and Social, 2007.
- Scott Nowson, Jon Oberlander, and Alastair J. Gill. Weblogs, genres and individual differences. In Proceedings of the 27th Annual Conference of the Cognitive Science Society, pages 1666–1671, 2005.
- Jon Oberlander and Alastair J. Gill. Language with character: A stratified corpus comparison of individual differences in e-mail communication. *Discourse Processes*, 42(3):239–270, 2006.

Expansão Google Scholar

Recurso muito bom para revisões bibliográficas. Existe também uma **extensão** de navegador que facilita a pesquisa.





Expansão Google Scholar

Nele, podemos pesquisar por artigos em qualquer repositório





Expansão Google Scholar

Além de podermos ver o perfil de autores





Walid Magdy
School of Informatics, The <u>University of Edinburgh</u>
E-mail confirmado em inf.ed.ac.uk - <u>Página inicial</u>
Computational Social Science Data Mining

Τίτυιο	CITADO POR	AN
Abusive language detection on Arabic social media H Mubarak, K Darwish, W Magdy Proceedings of the first workshop on abusive language online, 52-56	228	201
Content and Network Dynamics Behind Egyptian Political Polarization on Twitter J Borge-Holthoefer, W Magdy, K Darwish, I Weber CSCW	132	201
# FailedRevolutions: Using Twitter to Study the Antecedents ISIS Support W Magdy, K Darwish, I Weber First Monday 21 (2)	of 129	201
PRES: a score metric for evaluating recall-oriented informati retrieval applications W Magdy, GJF Jones Proceeding of the 33rd International ACM SIGIR conference on Research		201

Citado por		VER TODOS
	Todos	Desde 2017
Citações	3167	2345
Índice h	34	30
Índice i10	74	54
		620
		46

OBTER MEU PRÓPRIO PERFIL



Acesso publico	VER TODOS
0 artigo	35 artigos

Vantagens e desvantagens

Vantagens:

 Provavelmente, todos os artigos encontrados por essa forma serão de interesse ("precisão" grande)

Desvantagens:

 É muito possível que artigos importantes tenham sido deixados de fora ("revocação" pode ser baixa)



Revisão Sistemática



Revisão Sistemática

Possui 3 passos:

- Planejamento
- Condução
- Extração e Síntese de dados

Muitas vezes, por dar um panorama detalhado da área, pode virar um artigo a ser publicado.



Planejamento

- Passo <u>mais importante</u> de uma RS
- Se não for bem feito, vai gerar resultados indesejados e retrabalho
- O nível de detalhamento é diretamente proporcional à maturidade do projeto
- É comum conduzir uma revisão exploratória antes de iniciar a sistemática, para amadurecer o projeto



Planejamento Objetivos

Priorizar clareza e objetividade.

O objetivo deve ser condizente com o título.

É comum que o objetivo seja encontrar o estado-da-arte da área de interesse.



Estado da arte em detecção de posicionamentos em textos de redes sociais

Protocolo para Revisão Sistemática

Laís Carraro Leme Cavalheiro

Maio de 2022

1 Objetivos

Identificar na literatura a existência de trabalhos na área de detecção de posicionamentos em redes sociais que utilizam atributos textuais e não-textuais.

Planejamento Questões de pesquisa

Especificam os objetivos, e delineiam os dados que serão extraídos dos estudos incluídos.



2 Questões de pesquisa

- 1. Quais atributos de rede são utilizados?
- 2. Quais atributos de usuário são utilizados?
- 3. Como esses atributos são unidos aos atributos textuais?
- 4. Quais conjuntos de dados s\(\tilde{a}\) o usados para o treinamento e teste de modelos desse tipo?
- 5. Qual o idioma destes conjuntos de dados?
- 6. Com quais baselines estes resultados são comparados?

Planejamento Fontes

Repositórios em que a *string* de busca será inserida.

Podem ser mais gerais (ex.: Computação) ou mais específicos da área (ex.: Processamento de Língua Natural)



5 Listagem de fontes

- Biblioteca Digital da ACM (https://portal.acm.org/)
- Teses da USP (http://www.teses.usp.br/)
- Banco de teses da Capes (https://catalogodeteses.capes.gov.br/catalogoteses/)
- Portal Periódicos da Capes (http://novo.periodicos.capes.gov.br/)
- ACL Anthology (https://aclanthology.org/)

Planejamento Palavras-chave



String de busca que será utilizada para encontrar os estudos de interesse.

É preferível uma palavra-chave geral, para que todos os estudos de interesse sejam capturados.

4 Palavras-chave

"Stance".

Planejamento Critérios de inclusão

Determinam se um estudo será incluído ou não na RS.

Devem estar muito bem calibrados para gerar os resultados desejados.

Podem e devem ser ajustados com a Revisão Exploratória e com conduções de teste.



8.1 Critérios de inclusão

- Os trabalhos devem estar disponíveis integralmente em bases de dados científicas.
- Os trabalhos devem tratar sobre detecção de posicionamentos com dados de redes sociais.
- Os trabalhos devem ser uma revisão bibliográfica da área, ou propor um classificador ou um córpus que utiliza atributos não-textuais, mesmo que não sejam utilizados atributos textuais.

Planejamento Critérios de exclusão

Valem as mesmas recomendações dos critérios de inclusão.



8.2 Critérios de exclusão

- Serão excluídos trabalhos publicados antes de 2016.
- Serão excluídos trabalhos não relacionados a Processamento de Língua Natural ou Análise de Redes Sociais.
- Serão excluídos estudos de detecção de posicionamentos que propõem classificadores ou córpus que utilizam apenas dados textuais.

Planejamento Artigos de controle

Artigos encontrados na Revisão Exploratória.

Podem ser utilizados para testar e calibrar os critérios de inclusão e exclusão.



titulo	i1	i2	i3	e1	e2	e3	incluído
Stance Detection on Social Media: State of the Art and Trends	1	1	1	0	0	0	1
Multilingual stance detection in social media political debates	1	1	1	0	0	0	1
Unsupervised User Stance Detection on Twitter	1	1	1	0	0	0	1
Tweet Classification without the Tweet: An Empirical Examination of User versus I	1	1	1	0	0	0	1
Joint Non-negative Matrix Factorization for Learning Ideological Leaning on Twitte	1	1	1	0	0	0	1
Predicting Online Islamophobic Behavior after #ParisAttacks	1	1	1	0	0	0	1
Structured Representation Learning for Online Debate Stance Prediction	1	1	1	0	0	0	1
Weakly-Guided User Stance Prediction				0	0	0	1
Improved Stance Prediction in a User Similarity Feature Space	1	1	1	0	0	0	1
Detecção não supervisionada de posicionamento em textos de tweets	1	1	0	0	0	1	0
ISISisNotIslam or DeportAllMuslims?: Predicting Unspoken Views	1	1	1	0	0	0	1
Predicting User's Political Party Using Ideological Stances	1	1	0	1	0	0	0
SemEval-2016 Task 6: Detecting Stance in Tweets	1	1	0	0	0	1	0
Ideology Detection for Twitter Users with Heterogeneous Types of Links	1	1	1	0	0	0	1
Topic-factorized ideal point estimation model for legislative voting network	1	1	1	1	0	0	0
Modeling user arguments, interactions, and attributes for stance prediction in onlir	1	1	1	1	0	0	0

Planejamento Critérios de qualidade

Pontuação para priorização da leitura dos estudos incluídos.

No caso de a lista final possuir muitos estudos, pode ser feito um corte nesta lista através da pontuação.



9 Critérios de qualidade dos estudos primários

Os artigos devem ter sido publicados em periódicos ou anais de eventos com revisão por pares, e os trabalhos de conclusão de curso, mestrado ou doutorado devem ter sido aprovados pela banca examinadora.

Para os estudos primários selecionados, serão analisados os seguintes critérios de qualidade, associados a pontuações:

- O trabalho tem como foco especificamente o problema de detecção de posicionamentos. (10 pontos)
- O trabalho realiza comparações entre diferentes combinações de características textuais e não-textuais. (20 pontos)
- O trabalho é uma revisão sistemática de estudos da área. (5 pontos)

Estes critérios serão utilizados para estabelecer a ordem de priorização da leitura dos estudos primários incluídos.

Planejamento Estratégia de extração

Listagem de informações que serão extraídas dos artigos de interesse.

Não listar todos os campos necessários pode gerar retrabalho na leitura dos estudos. Por isso, podem e devem ser alterados durante a condução e a extração de teste.



11 Estratégia de extração de informação

Para cada trabalho selecionado no passo anterior, será preenchido um formulário de extração de dados. Além das informações básicas (dados bibliográficos, data de publicação, resumo), os formulários deverão listar as seguintes características específicas, relacionadas às questões de pesquisa:

- Atributos utilizados no classificador
- Tipo de classificador
- Conjuntos de dados
- Idioma dos conjuntos de dados
- Baselines de comparação

Por fim, esses formulários deverão conter a síntese do trabalho, redigida pelo pesquisador que conduzirá a Revisão Sistemática, e reflexões pessoais a respeito do conteúdo e das conclusões do estudo.

Condução

- Nesta fase, pesquisamos efetivamente os estudos nos repositórios listados
- Avaliamos também sua inclusão (muitas vezes, é a etapa mais trabalhosa)
- E sua qualidade



Condução Condução teste

Condução em uma das fontes listadas.

Com ela, podemos avaliar os critérios de inclusão/ exclusão, volume de artigos, filtros, etc.



Condução da Revisão Sistemática

Laís Carraro Leme Cavalheiro 2 de junho de 2022

1 Informações

- Fonte: Biblioteca Digital do IEEE (http://ieeexplore.ieee.org/Xplore/dynhome.jsp)
- 2. Data: 02/06/2022
- 3. String de busca: "stance"
- 4. Período: 2016 a 2022
- Filtros: Foram incluídos apenas os tópicos "learning (artificial intelligence)", "social networking (online)", "pattern classification" e "text analysis"

Condução Planilha de buscas

É uma boa prática documentar as buscas realizadas, assim como a data e o número de resultados.

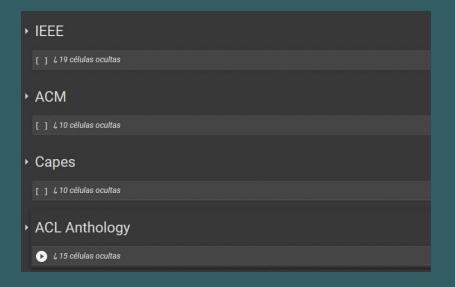


id_busca	fonte	link	data	string_busca	periodo	filtros	resultados
1	IEEE	http://ieeexplore.	02/06/2022	"stance"	2016 a 2022	Foram incluídos apenas os tópicos "learning (artificial intelligence)", "social networking (online)", "pattern classification" e "text analysis"	157
2	IEEE	http://ieeexplore.	25/08/2022	"stance"	2016 a 2022	Foram incluídos apenas os tópicos "social networking (online)", "text analysis" e "feature extraction"	145
3	ACM	https://portal.acn	15/09/2022	"stance"	2016 a 2022	[Title: "stance"] AND [Abstract: "stance"] AND [Publication Date: (01/01/2016 TO 12/31/2022)]	137
4	Teses da USP	http://www.teses	15/09/2022	"stance"	2016 a 2022	Título "stance" e Resumo "stance"	0
5	Banco de teses	https://catalogod	15/09/2022	"stance"	2016 a 2022	Foram incluídos apenas os estudos com a grande área do conhecimento "Ciências exatas e da Terra"	1
6	Periódicos da (http://novo.perio	15/09/2022	"stance"	2016 a 2022	Foram incluídos apenas artigos revisados por pares, em inglês e português, das áreas "Technology" e "Computer Science". Foram excluídos os assuntos "Engineering" e "Robotics"	180
7	ACL Anthology	https://aclantholo	15/09/2022	"stance"	2016 a 2022	"stance" em qualquer campo	145

Condução Scripts de padronização

Uma dica para facilitar a condução é utilizar um script para cada fonte de busca, já que a exportação de referências pode ter tipos de arquivos ou campos diferentes, dependendo da fonte





Condução Scripts de padronização

Algumas libs como o bibtexparser podem ser interessantes para manipular os arquivos de referências



```
import bibtexparser
```

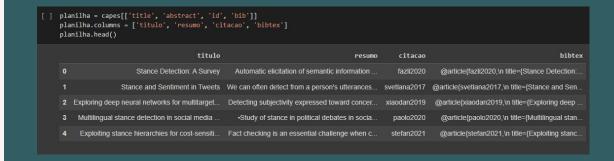
with open('/content/drive/MyDrive/Mestrado/Projeto de bib_database1 = bibtexparser.load(bibtex_file1)

import pandas as pd
capes = pd.DataFrame(bib_database1.entries)

Condução Scripts de padronização

Após o processamento, uma dica é escolher apenas os campos que serão utilizados na avaliação de inclusão e padronizar todas as buscas





Condução Planilha de inclusão

Dessa forma, podemos criar uma planilha padronizada para a avaliação de inclusão



d_busca	id_artigo	titulo	r∈ c b	i1	i2	i3	e1	e2	e3	incluido
1	0	Predicting Stance Polarity and Intensity in Cyber Argumentation With Deep Bidirectional Transformers	Ir a €	1	0	0	0	0	0	0
2	0	Predicting Stance Polarity and Intensity in Cyber Argumentation With Deep Bidirectional Transformers	Ir a €	1	0	0	0	0	0	0
1	1	Text Stance Detection Based on Deep Learning	S ji @	1	1	0	0	0	1	0
1	2	What is Real or Fake?-Machine Learning Approaches for Rumor Verification using Stance Classification	Ir fi €	1	1	0	0	0	1	0
3	2	What is Real or Fake?-Machine Learning Approaches for Rumor Verification using Stance Classification	Ir fi €	1	1	0	0	0	1	0
1	3	A Token Level Multi-target Stance Detection Dataset	M li €	1	1	0	0	0	1	0
2	3	A Token Level Multi-target Stance Detection Dataset	M Ii @	1	1	0	0	0	1	0
1	4	A Two-Phase Approach for Stance Classification in Twitter Using Name Entity Recognition and Term Frequency	Pn@	1	1	0	0	0	1	0
2	4	A Two-Phase Approach for Stance Classification in Twitter Using Name Entity Recognition and Term Frequency	Pn@	1	1	0	0	0	1	0
1	5	Bidirectional Perspective with Topic Information for Stance Detection	Bk€	1	1	0	0	0	1	0
2	5	Bidirectional Perspective with Topic Information for Stance Detection	B k €	1	1	0	0	0	1	0
1	6	Claim Stance Classification Optimized by Data Augment	Ay@	1	1	0	0	0	1	0
2	6	Claim Stance Classification Optimized by Data Augment	Ay@	1	1	0	0	0	1	0
1	7	Stance Detection Using Multi-Head Attention Based Bidirectional GRU	Ir h €	1	1	1	0	0	0	1
2	7	Stance Detection Using Multi-Head Attention Based Bidirectional GRU	Ir h €	1	1	1	0	0	0	1
1	8	BiLSTM-Autoencoder Architecture for Stance Prediction	T d @	1	1	0	0	0	1	0
2	8	BiLSTM-Autoencoder Architecture for Stance Prediction	T d @	1	1	0	0	0	1	0
1	9	Classification of locomotive disorders based on stance parameters	Ts@	1	0	0	0	1	0	0
1	10	SRLF: A Stance-aware Reinforcement Learning Framework for Content-based Rumor Detection on Social Media	Th@	1	0	0	0	0	1	0
2	10	SRLF: A Stance-aware Reinforcement Learning Framework for Content-based Rumor Detection on Social Media	Th@	1	0	0	0	0	1	0

Condução Planilha de qualidade

E, posteriormente, uma planilha similar para a avaliação da qualidade dos estudos incluídos



id_artigo =	titulo =	bibtex_revis =	Ŧ	=	$\bar{\tau}$	citacao =	pontuação	Ŧ
23	We Like, We Post: A Joint U	@article{ku2018	1	1	0	ku2018		30
205	Your Stance is Exposed! An	@article{walid20	1	1	0	walid2019		30
217	Stance Classification through	@article{mohane	1	1	0	mohand2018		30
241	Stance Polarity in Political D	@article{paolo2(1	1	0	paolo2019		30
242	Improved Stance Prediction	@article{tahar20	1	1	0	tahar2017		30
326	Brexit: Leave or remain? the	@article{paolo2(1	1	0	paolo2020		30
336	Multilingual stance detection	@article{paolo2(1	1	0	paolo2020		30
349	Friends and Enemies of Clir	@article{paolo2(1	1	0	paolo2017		30
493	OK Boomer: Probing the so	@article{lucie20.	1	1	0	lucie2022		30
551	Tweet Classification without	@article{andrew	1	1	0	andrew2019		30
618	Tohoku at SemEval-2016 Ta	@article{kentaro	1	1	0	kentaro2016		30
37	Rumor Stance Classification	@article{xia2019	0	1	0	xia2019		20
57	Stance Classification and R	@article{aono20	0	1	0	aono2020		20
81	Socially Aware Multimodal [@article{li2021,	0	1	0	li2021		20
101	No, That Never Happened!!	@article{singh20	0	1	0	singh2018		20
298	Every Colour You Are: Stan	@article{mounia	0	1	0	mounia2020		20
337	Discourse-aware rumour sta	@article{isabelle	0	1	0	isabelle2018		20
597	UWaterloo at SemEval-2017	@article{olga20*	0	1	0	olga2017		20
607	Human Centered NLP with	@article{andrew	0	1	0	andrew2017		20
40	A Survey on Opinion Mining	@article{yang20	1	0	1	yang2019		15

Extração e síntese

- Nesta etapa, os artigos selecionados são lidos por inteiro
- Se o protocolo estiver bem estruturado, será necessário ler os estudos apenas uma vez
- Após a extração, o ideal é redigir um relatório ou artigo para sumarizar as tendências encontradas



Vantagens e desvantagens

Vantagens:

- Metodologia bem estruturada e replicável
- Visão meticulosa da área
- o Conhecimento do estado-da-arte

• Desvantagens:

- Trabalhoso
- Um planejamento fraco pode levar ao retrabalho

